Martín Cogo

Computer Vision Engineer | Percepción visual en tiempo real y Edge AI

Godoy Cruz, Mendoza, Argentina | martincogo3@gmail.com | mrtc101.github.io/MrtC101 | linkedin.com/in/martin-cogo
github.com/MrtC101

Resumen

Desarrollo sistemas de visión por computadora en tiempo real sobre GPU NVIDIA: pipelines GStreamer/DeepStream que corren modelos TensorRT sobre cámaras RTSP en vivo, con telemetría por etapas para medir y optimizar la latencia. En MindColab bajé la latencia de un pipeline en vivo de ~1,1 s a ~39 ms y soy autor del 98% de los commits de una plataforma edge de 12 componentes. Licenciado en Ciencias de la Computación (UNCUYO), mejor promedio de la promoción 2024. Busco roles de Computer Vision / Perception Engineer.

Experiencia Laboral

MindColab

Computer Vision Software Engineer (Part-time)
Jul 2025 – presente
Motor de inferencia en tiempo real y plataforma edge para la inspección visual de cintas transportadoras en minería. Procesa varias cámaras RTSP en vivo con GStreamer/DeepStream y TensorRT, con los frames en memoria de GPU (NVMM).

- **Latencia**: Bajé la latencia del pipeline en vivo de ~1,1 s a ~39 ms de media (~28×; p99 de 76 ms frente a un presupuesto de 200 ms por frame) y la pérdida de frames de 17,9% a 0,11% en régimen estable. Quité dos esperas ocultas que expuso mi telemetría: un encoder que bloqueaba los hilos de arriba y la sincronización de reloj del publisher.
- **Telemetría por etapas**: Diseñé e implementé la telemetría del motor: 48 métricas de tiempo por job, probes en cada elemento GStreamer, tiempos de GPU con eventos CUDA, histogramas logarítmicos fusionables (p50/p95/p99) en ventanas de 5 s y una API REST con métricas de GPU, CPU y RAM.
- **Modelos**: 2 modelos TensorRT FP16 por frame: DINOv2-small detecta objetos extraños (anomalías) y FastSAM-s segmenta rocas y mide su tamaño. Comparé Dinomaly y EfficientAD, y validé las exportaciones a ONNX y TensorRT contra el checkpoint original de PyTorch.
- **Operación 24/7**: Workers que se recuperan solos: 8 reinicios automáticos en ~1 h ante caídas de la fuente RTSP, cada uno en 34–36 s y sin intervención manual. Restart controlado, hot-reload de configuración con un DSL propio y graceful shutdown.
- **Plataforma**: Autor principal (98% de 2717 commits) de una plataforma edge de 12 componentes: microservicios FastAPI, ZMQ, Redis, una SPA en React con video WebRTC en vivo y logs centralizados (Fluent Bit + VictoriaLogs), desplegada con k3s y Helm para NVIDIA Jetson.

Stack: Python, GStreamer, DeepStream, TensorRT, CUDA, PyTorch, ONNX, Anomalib, Ultralytics, OpenCV, FastAPI, ZMQ, Redis, React, Docker, k3s, Helm

Municipalidad de Godoy Cruz

Desarrollador Web (Part-time)
Jun 2025 – Sep 2026
Mantenimiento y extensión de la aplicación web de pago de deudas y tasas municipales (Java generado con GeneXus).

- **Integraciones de pago**: Refactoricé las integraciones con 6 pasarelas de pago bancarias (Banco Macro, Mercado Pago, ePagos, XNet, Pago Fácil, Supervielle) en el flujo de envío de montos y transacciones.
- **Chat con LLM**: Desarrollé una interfaz de chat interna para consultar normativas municipales mediante búsqueda semántica y un LLM (ver proyecto).

Stack: Java, GeneXus, Tomcat, Nginx, React, Tailwind, Bun

Klari Inc.

Científico de Datos (Pasantía, 200 hs)
Ene 2025 – Feb 2025
Análisis semántico de las conversaciones de un chatbot basado en LLM, con reportes sobre la calidad de la interacción.

- **Pipeline NLP**: Embeddings de las conversaciones y clustering no supervisado para detectar temas recurrentes.

Stack: Python, NumPy, Pandas, Scikit-learn, PyTorch, FastAPI, MongoDB

Grupo CICDa
Investigador de Tesis de Grado
Ene 2024 – Ene 2025
Tesis sobre evaluación de daños en edificios tras desastres naturales con imágenes satelitales: una U-Net siamesa multitarea que segmenta edificios y clasifica su daño en 4 niveles a partir de imágenes previas y posteriores al desastre (código · tesis).

- **Pipeline completo**: Preprocesamiento, entrenamiento, inferencia y post-procesamiento sobre ~3000 imágenes satelitales VHR del dataset xBD, con una estrategia propia de muestreo greedy para balancear las clases de daño.
- **Resultados**: F1 de 0,80 en segmentación de edificios sobre el conjunto de test, con evaluación a nivel de píxel y de objeto.
- **Cómputo**: Entrenamiento en un clúster HPC con GPUs NVIDIA Tesla V100.

Stack: Python, PyTorch, Pandas, Scikit-learn, OpenCV, Linux, Git

Habilidades Técnicas

Lenguajes: Python, TypeScript/JavaScript, C/C++

Visión e Inferencia: GStreamer, DeepStream, TensorRT, CUDA, ONNX, OpenCV

IA & ML: PyTorch, Ultralytics, Anomalib, Scikit-learn, Pandas, NumPy

Backend, APIs REST y Web: FastAPI, ZMQ, Nginx, React, Tailwind

Bases de Datos: Redis, SQLite, MongoDB

DevOps y Herramientas: Docker, k3s, Helm, Linux, Git

Educación

Universidad Nacional de Cuyo
Licenciatura en Ciencias de la Computación, Grado (Promedio 8,7)
2020 – 2024

Premios

- Medalla al mejor promedio de la promoción 2024 de la Licenciatura en Ciencias de la Computación.
- Cuadro de honor (top 15 promedios) de la Facultad de Ingeniería, UNCUYO, 2024.

Idiomas

- Español: Nativo.
- Inglés: Nivel B2 (Certificado por Cambridge).